

Desenvolvimento de um fluxo de trabalho de modelação metabólica para o estudo de comunidades microbianas

Bruno Ferreira; Artur Gomes; Andreia Salvador; Óscar Dias

Universidade do Minho, Portugal

pg58814@uminho.pt

Resumo Este projeto propõe o desenvolvimento de um *workflow* implementado em Snakemake para a reconstrução automatizada de modelos metabólicos à escala do genoma (*genome-scale metabolic models*, GEMs) a partir de *metagenome-assembled genomes* (MAGs) previamente obtidos e avaliados. O *workflow* integra, numa *pipeline* única e rastreável, etapas de controlo de qualidade genómica, reconstrução automática de GEMs com CarveMe, e simulação de interações metabólicas ao nível da comunidade com SMETANA, SteadyCom e MICOM. A estrutura modular, baseada em *wrappers* Snakemake, permite substituir ou adaptar componentes individuais sem alterar o restante fluxo de trabalho, facilitando a sua aplicação a diferentes conjuntos de MAGs e contextos metagenómicos. O projeto contribui para reduzir a fragmentação metodológica que caracteriza atualmente a análise metabólica de comunidades microbianas, proporcionando uma solução computacional documentada, versionada e reproduzível.

Keywords: Modelos Metabólicos à Escala Genómica (GEMs) · Análise de Balanço de Fluxos (FBA) · Interações Metabólicas · Pipeline Computacional

1 Contexto e motivação

A metagenómica *shotgun* tem vindo a transformar o estudo de comunidades microbianas, ao permitir aceder ao conteúdo genético de microrganismos diretamente a partir de amostras ambientais ou clínicas, sem necessidade de cultivo [1,2]. A partir destes dados, é possível reconstruir *metagenome-assembled genomes* (MAGs), que constituem uma representação aproximada dos genomas dos organismos presentes numa comunidade e uma base importante para análises funcionais mais detalhadas [2,3]. Entre essas análises, a modelação metabólica à escala do genoma assume particular relevância, uma vez que permite construir modelos capazes de descrever o potencial metabólico de cada organismo e apoiar simulações *in silico*. Quando estes modelos são considerados em conjunto, torna-se possível estudar propriedades emergentes de comunidades microbianas, incluindo competição por nutrientes, partilha de metabolitos e outras formas de interação ecológica.

Apesar de existirem ferramentas para a reconstrução de modelos metabólicos e para simulação de comunidades, estas etapas continuam frequentemente distribuídas por programas distintos, com formatos de entrada e saída heterogêneos, dependências próprias e pressupostos metodológicos nem sempre compatíveis. Esta fragmentação dificulta a integração das diferentes etapas analíticas e compromete a reprodutibilidade, a rastreabilidade e a reutilização dos processos computacionais. Existem já precedentes de *pipelines* que ligam dados metagenômicos à modelação metabólica de comunidade, como o *metaGEM*, demonstrando que esta abordagem é viável [4]. Ainda assim, continua a existir espaço para soluções mais modulares e mais facilmente adaptáveis a diferentes contextos de análise. Neste enquadramento, o presente projeto tem como objetivo desenvolver um *workflow* modular e reprodutível, implementado em Snakemake, orientado para dados de entrada já assemblados [5]. Em vez de abranger todas as etapas da análise metagenómica, a proposta incide sobre a integração das fases subsequentes, desde a utilização de MAGs previamente obtidos e avaliados até à reconstrução de modelos metabólicos e à sua aplicação em ferramentas de simulação ao nível da comunidade.

1.1 Objetivos

Este projeto tem como objetivo desenvolver um *workflow* modular e reprodutível para modelação metabólica de comunidades microbianas a partir de genomas previamente assemblados, com foco particular em MAGs. A proposta incide sobre a integração, num fluxo de trabalho único, da avaliação da qualidade dos genomas de entrada, da reconstrução de modelos metabólicos à escala do genoma e da sua posterior utilização em ferramentas de simulação ao nível da comunidade. Para esse efeito, o *workflow* será implementado em Snakemake e estruturado de forma a promover automatização, rastreabilidade e reutilização. Os modelos metabólicos gerados serão depois utilizados para explorar interações metabólicas entre membros da comunidade com recurso ao SMETANA, ao SteadyCom e ao MICOM, de modo a inferir padrões de competição, partilha de metabolitos e crescimento comunitário.

2 Estado da Arte

A compreensão funcional de comunidades microbianas passa pela integração de dados genómicos com abordagens de modelação metabólica. Esta secção apresenta o estado da arte nos domínios relevantes para o presente trabalho: a reconstrução de MAGs a partir de dados metagenómicos, a construção de modelos metabólicos à escala do genoma e a modelação metabólica ao nível da comunidade.

2.1 Metagenómica e Reconstrução de MAGs

A metagenómica *shotgun* permitiu a recuperação independente de cultivo de genomas diretamente a partir de amostras ambientais, alargando substancialmente

a diversidade microbiana acessível à análise genómica [1,2,7]. Os MAGs resultam de etapas como montagem, *binning* e refinamento, sendo a sua qualidade um fator determinante para qualquer análise funcional ou metabólica a jusante. Bowers et al. propuseram as normas MIMAG/MISAG, segundo as quais a completude e a contaminação constituem métricas essenciais para a avaliação destes genomas [3]. De acordo com estes critérios, um MAG de alta qualidade deve apresentar mais de 90% de completude e menos de 5% de contaminação, enquanto um MAG de qualidade média deve apresentar pelo menos 50% de completude e menos de 10% de contaminação [3].

A qualidade dos MAGs condiciona diretamente a reconstrução de modelos metabólicos, uma vez que a inferência de vias e funções depende da integridade e fiabilidade do conteúdo génico disponível. MAGs incompletos podem omitir genes essenciais de determinadas vias, enquanto MAGs contaminados podem introduzir associações funcionais incorretas. Assim, a robustez da reconstrução metabólica depende, em primeiro lugar, da qualidade dos genomas utilizados como entrada [8].

2.2 Modelação metabólica e reconstrução de GEMs

Um *genome-scale metabolic model* (GEM) constitui uma representação matemática estruturada do metabolismo de um organismo, integrando metabolitos, reações, associações gene-proteína-reação e restrições biofísicas. Estes modelos permitem estudar capacidades metabólicas, prever a utilização de vias e simular fenótipos de crescimento [9,10]. A base teórica mais utilizada neste contexto é o *Flux Balance Analysis* (FBA), uma abordagem de modelação *constraint-based* que descreve os fluxos metabólicos assumindo estado estacionário interno e uma função objetivo, frequentemente associada à biomassa [9].

A reconstrução de um GEM é, idealmente, um processo rigoroso e iterativo de curadoria e validação [10]. No entanto, esse processo é exigente em tempo e esforço manual, o que motivou o desenvolvimento de ferramentas automáticas. Entre estas, o CarveMe destacou-se por permitir a geração rápida de modelos metabólicos para espécies microbianas e comunidades, recorrendo a uma abordagem *top-down* baseada num modelo universal previamente curado [11]. A interoperabilidade constitui também um aspeto central nestas análises, pelo que a utilização de formatos padronizados e de identificadores consistentes para reações e metabolitos é fundamental. Neste contexto, a base de dados BiGG Models assume particular relevância ao disponibilizar identificadores estandardizados e facilitar a integração, partilha e reutilização de GEMs em diferentes contextos computacionais [12].

2.3 Modelação metabólica de comunidades

Os modelos metabólicos de organismos individuais são úteis para descrever capacidades metabólicas específicas, mas não representam diretamente propriedades emergentes de comunidades microbianas, como competição por recursos, *cross-feeding*, dependências metabólicas e coexistência estável. Neste sentido,

a modelação metabólica ao nível da comunidade tornou-se uma abordagem relevante para investigar interações funcionais entre múltiplos microrganismos.

Entre os trabalhos mais relevantes neste domínio encontra-se o *metaGEM*, apresentado por Zorrilla et al., que estabelece uma ligação entre dados metagenómicos e modelação metabólica comunitária através da reconstrução de modelos metabólicos diretamente a partir de metagenomas [4]. A aplicação deste *pipeline* a diferentes ambientes demonstrou o potencial desta abordagem para estudar variação metabólica específica de cada comunidade e inferir interações metabólicas entre espécies [4].

2.4 Ferramentas de simulação ao nível da comunidade

A simulação de interações metabólicas em comunidades microbianas pode ser abordada com diferentes ferramentas computacionais, cada uma assente em pressupostos e objetivos distintos. Entre as ferramentas consideradas neste projeto, o SMETANA, o SteadyCom e o MICOM respondem a questões complementares.

O SMETANA insere-se na linha de trabalho de Zelezniak et al. sobre dependências metabólicas entre espécies e pode ser descrito como uma abordagem *constraint-based* para inferir o potencial de *cross-feeding* e de interdependência metabólica entre membros de uma comunidade [14,15,16]. A ferramenta calcula métricas globais de sobreposição de recursos e de potencial de interação metabólica, podendo ainda caracterizar dependências ao nível de pares de organismos [15,16].

O SteadyCom é um método desenvolvido para prever distribuições de fluxos metabólicos e abundâncias relativas compatíveis com estado estacionário ao nível da comunidade [17]. Os autores descrevem-no como um *framework* de otimização que impõe uma taxa de crescimento comunitário comum aos diferentes membros, permitindo identificar composições metabolicamente compatíveis com coexistência estável [17].

O MICOM é uma ferramenta de modelação comunitária baseada em modelos à escala do metagenoma, concebida para integrar abundâncias relativas e restrições ambientais [18]. Um dos seus aspetos centrais é a estratégia de *cooperative trade-off*, que procura um compromisso entre o crescimento da comunidade e o crescimento individual dos seus membros [18]. Em conjunto, estas três ferramentas oferecem perspetivas complementares sobre interações metabólicas, crescimento comunitário e fluxos de troca entre organismos.

3 Gestão de workflows e reprodutibilidade

A construção de *pipelines* bioinformáticas reprodutíveis constitui um requisito central em análises computacionais complexas, particularmente quando os resultados dependem da execução encadeada de múltiplas ferramentas, parâmetros e versões de software [19,20]. Em investigação computacional, a reprodutibilidade exige não apenas a disponibilização de dados e código, mas também a capacidade de reconstruir explicitamente como cada resultado foi obtido, evitando etapas

manuais não documentadas e preservando as versões exatas das dependências utilizadas [19,20]. No contexto deste projeto, esta necessidade é particularmente relevante, uma vez que o *workflow* proposto integra diferentes etapas de modelação metabólica a partir de genomas assemblados ou MAGs, recorrendo a ferramentas distintas para análise ao nível da comunidade microbiana.

3.1 Snakemake

O Snakemake é um sistema de gestão de *workflows* concebido para automatizar análises de dados de forma legível, escalável e reprodutível [5,6]. No trabalho original de Köster e Rahmann, o Snakemake é descrito como um *workflow engine* com uma linguagem de definição baseada em Python, capaz de inferir automaticamente dependências e paralelização a partir de regras descritas pelos seus ficheiros de entrada e saída [5]. Esta abordagem permite representar uma *pipeline* como um grafo acíclico dirigido, no qual cada regra corresponde a uma transformação explícita de dados, facilitando a rastreabilidade e a manutenção do *workflow* [5]. Uma das principais vantagens do Snakemake é a sua capacidade de escalar da execução local para ambientes de computação distribuída, incluindo *clusters* e infraestruturas em nuvem, sem necessidade de alterar a definição do *workflow* [5]. Além disso, o Snakemake permite associar explicitamente software e dependências a cada etapa, promovendo isolamento computacional e maior controlo sobre a execução [6,21].

3.2 Wrappers e modularização da pipeline

A modularização constitui um princípio importante no desenho de *workflows* bioinformáticos, uma vez que reduz o acoplamento entre etapas, facilita a manutenção e promove a reutilização de componentes em diferentes contextos analíticos. Na documentação oficial do Snakemake, os *wrappers* correspondem à unidade mais granular de modularização [13]. Um *wrapper* pode ser entendido, neste contexto, como uma abstração reutilizável em torno de uma ferramenta de linha de comandos, encapsulando a sua invocação, os seus parâmetros, os seus ficheiros de entrada e saída e, quando aplicável, o ambiente de software necessário para a sua execução [13].

Do ponto de vista da reprodutibilidade, os *wrappers* são particularmente relevantes porque podem ser referidos por versões específicas ou identificadores imutáveis, permitindo controlar explicitamente a implementação utilizada em cada etapa do *workflow* [13]. Esta abordagem favorece uma execução mais reprodutível, uma manutenção mais simples e a futura reutilização dos componentes da *pipeline* em diferentes contextos analíticos.

4 Workflow proposto

A Figura 1 resume a estrutura geral do *workflow* proposto para reconstrução de modelos metabólicos a partir de MAGs ou genomas previamente assemblados e

posterior simulação ao nível da comunidade. O fluxo de trabalho organiza-se nas seguintes etapas principais:

1. **Preparação dos dados de entrada.** Recolha e organização dos MAGs ou genomas previamente assemblados que servirão de base à análise.
2. **Avaliação da qualidade dos genomas.** Aplicação de métricas de completude e contaminação com recurso ao CheckM, retendo apenas os genomas que satisfaçam critérios mínimos de qualidade consistentes com as recomendações MIMAG [3,8].
3. **Reconstrução automática de GEMs.** Geração de modelos metabólicos à escala do genoma com o CarveMe, em formato compatível com as etapas subsequentes de análise [11,12].
4. **Verificação e compatibilização dos modelos.** Avaliação da viabilidade básica dos modelos gerados e harmonização de identificadores de metabolitos e reações, de modo a garantir a sua utilização consistente em contexto comunitário.
5. **Simulação ao nível da comunidade.** Aplicação dos modelos validados no SMETANA, no SteadyCom e no MICOM, com o objetivo de explorar dependências metabólicas, crescimento comunitário, abundâncias relativas e possíveis fluxos de troca entre organismos [15,16,17,18].
6. **Análise comparativa dos resultados.** Comparação dos resultados produzidos pelas três ferramentas, incidindo sobre: (i) os metabolitos potencialmente partilhados ou competidos entre organismos; (ii) as dependências metabólicas inferidas pelo SMETANA; e (iii) as estimativas de crescimento e abundância obtidas com SteadyCom e MICOM. Esta comparação permitirá identificar convergências entre métodos e resultados específicos de cada abordagem.

Embora ainda provisório, este esquema explicita a organização geral da *pipeline* e a sua implementação modular em Snakemake.



Figura 1. Esquema geral do *workflow* proposto para reconstrução de modelos metabólicos a partir de MAGs ou genomas previamente assemblados e posterior simulação ao nível da comunidade.

Referências

1. Tyson, G.W., Chapman, J., Hugenholtz, P., Allen, E.E., Ram, R.J., Richardson, P.M., Solovyev, V.V., Rubin, E.M., Rokhsar, D.S., Banfield, J.F.: Community structure and metabolism through reconstruction of microbial genomes from the environment. *Nature* **428**(6978), 37–43 (2004). <https://doi.org/10.1038/nature02340>
2. Parks, D.H., Rinke, C., Chuvochina, M., Chaumeil, P.-A., Woodcroft, B.J., Evans, P.N., Hugenholtz, P., Tyson, G.W.: Recovery of nearly 8,000 metagenome-assembled genomes substantially expands the tree of life. *Nature Microbiology* **2**(11), 1533–1542 (2017). <https://doi.org/10.1038/s41564-017-0012-7>
3. Bowers, R.M., Kyrpides, N.C., Stepanauskas, R., Harmon-Smith, M., Doud, D., Reddy, T.B.K., Schulz, F., Jarett, J., Rivers, A.R., Elie-Fadrosh, E.A., et al.: Minimum information about a single amplified genome (MISAG) and a metagenome-assembled genome (MIMAG) of bacteria and archaea. *Nature Biotechnology* **35**(8), 725–731 (2017). <https://doi.org/10.1038/nbt.3893>
4. Zorrilla, F., Buric, F., Patil, K.R., Zelezniak, A.: metaGEM: reconstruction of genome scale metabolic models directly from metagenomes. *Nucleic Acids Research* **49**(21), e126 (2021). <https://doi.org/10.1093/nar/gkab815>
5. Köster, J., Rahmann, S.: Snakemake—a scalable bioinformatics workflow engine. *Bioinformatics* **28**(19), 2520–2522 (2012). <https://doi.org/10.1093/bioinformatics/bts480>
6. Mölder, F., Jablonski, K.P., Letcher, B., Hall, M.B., Tomkins-Tinch, C.H., Sochat, V., Forster, J., Lee, S., Twardziok, S.O., Kanitz, A., Wilm, A., Holtgrewe, M., Rahmann, S., Nahnsen, S., Köster, J.: Sustainable data analysis with Snakemake. *F1000Research* **10**, 33 (2021). <https://doi.org/10.12688/f1000research.29032.3>
7. Nayfach, S., Roux, S., Seshadri, R., Udway, D., Varghese, N., Schulz, F., Wu, D., Paez-Espino, D., Chen, I.-M.A., Huntemann, M., Palaniappan, K., Ladau, J., Mukherjee, S., Reddy, T.B.K., Nielsen, T., Kirton, E., Faria, J.P., Edirisinghe, J.N., Henry, C.S., Jungbluth, S.P., Chivian, D., Dehal, P., Wood-Charlson, E.M., Arkin, A.P., Tringe, S.G., Visel, A., IMG/M Data Consortium, Woyke, T., Mouncey, N.J., Ivanova, N.N., Kyrpides, N.C., Elie-Fadrosh, E.A.: A genomic catalog of Earth’s microbiomes. *Nature Biotechnology* **39**(4), 499–509 (2021). <https://doi.org/10.1038/s41587-020-0718-6>
8. Parks, D.H., Imelfort, M., Skennerton, C.T., Hugenholtz, P., Tyson, G.W.: CheckM: assessing the quality of microbial genomes recovered from isolates, single cells, and metagenomes. *Genome Research* **25**(7), 1043–1055 (2015). <https://doi.org/10.1101/gr.186072.114>
9. Orth, J.D., Thiele, I., Palsson, B.Ø.: What is flux balance analysis? *Nature Biotechnology* **28**(3), 245–248 (2010). <https://doi.org/10.1038/nbt.1614>
10. Thiele, I., Palsson, B.Ø.: A protocol for generating a high-quality genome-scale metabolic reconstruction. *Nature Protocols* **5**(1), 93–121 (2010). <https://doi.org/10.1038/nprot.2009.203>
11. Machado, D., Andrejev, S., Tramontano, M., Patil, K.R.: Fast automated reconstruction of genome-scale metabolic models for microbial species and communities. *Nucleic Acids Research* **46**(15), 7542–7553 (2018). <https://doi.org/10.1093/nar/gky537>
12. King, Z.A., Lu, J., Dräger, A., Miller, P., Federowicz, S., Lerman, J.A., Ebrahim, A., Palsson, B.Ø., Lewis, N.E.: BiGG Models: A platform for integrating, standardizing and sharing genome-scale models. *Nucleic Acids Research* **44**(D1), D515–D522 (2016). <https://doi.org/10.1093/nar/gkv1049>

13. Snakemake documentation: Modularization. [https://snakemake.readthedocs.io/en/stable/snakefiles/modularization.h](https://snakemake.readthedocs.io/en/stable/snakefiles/modularization.html)
last accessed 2026/04/05
14. Zelezniak, A., Andrejev, S., Ponomarova, O., Mende, D.R., Bork, P., Patil, K.R.: Metabolic dependencies drive species co-occurrence in diverse microbial communities. *Proceedings of the National Academy of Sciences of the United States of America* **112**(20), 6449–6454 (2015). <https://doi.org/10.1073/pnas.1421834112>
15. SMETANA documentation: Algorithms. <https://smetana.readthedocs.io/en/latest/algorithms.html>,
last accessed 2026/04/05
16. SMETANA documentation: Usage. <https://smetana.readthedocs.io/en/latest/usage.html>,
last accessed 2026/04/05
17. Chan, S.H.J., Simons, M.N., Maranas, C.D.: SteadyCom: Predicting microbial abundances while ensuring community stability. *PLoS Computational Biology* **13**(5), e1005539 (2017). <https://doi.org/10.1371/journal.pcbi.1005539>
18. Diener, C., Gibbons, S.M., Resendis-Antonio, O.: MICOM: Metagenome-scale modeling to infer metabolic interactions in the gut microbiota. *mSystems* **5**(1), e00606-19 (2020). <https://doi.org/10.1128/mSystems.00606-19>
19. Mesirov, J.P.: Accessible reproducible research. *Science* **327**(5964), 415–416 (2010). <https://doi.org/10.1126/science.1179653>
20. Sandve, G.K., Nekrutenko, A., Taylor, J., Hovig, E.: Ten simple rules for reproducible computational research. *PLoS Computational Biology* **9**(10), e1003285 (2013). <https://doi.org/10.1371/journal.pcbi.1003285>
21. Snakemake documentation. <https://snakemake.readthedocs.io/en/stable/>, last accessed 2026/04/05